Data Science sous R

Chapitre 1 — Introduction à la science des données

ESME — 2026-2027

Table des matières

1 Introduction à la science des données **2**
1.1 Qu'est-ce que la science des données ? 2
1.2 Science des données véridique 4
1.3 Le cadre PCS : prédictibilité, calculabilité, stabilité 5
1.4 Le cycle de vie d'un projet de science des données 7
1.5 Résumé 8
1.6 Exercices 8

Chapitre 1

Introduction à la science des données

Objectifs du chapitre

- Comprendre ce qu'est la science des données et à quoi elle sert, notamment en marketing.
- Savoir pourquoi un résultat issu de données doit être évalué avec un regard critique.
- Connaître le cadre PCS (prédictibilité, calculabilité, stabilité) et savoir découper des données en ensembles d'entraînement, de validation et de test.
- Connaître le cycle de vie d'un projet de science des données.

Support de cours : diaporama `01-Science-des-donnees.pdf`. Les exercices sont regroupés en fin de chapitre.

1.1 Qu'est-ce que la science des données ?

1.1.1 Une pratique ancienne, un nom récent

Utiliser des données pour répondre à des questions concrètes n'est pas nouveau : on parlait autrefois d'« analyse de données » ou de « statistique appliquée ». Le traitement automatisé des données commence avec les cartes perforées d'Herman Hollerith, conçues pour dépouiller le recensement américain de 1890 ; sa société est l'une des quatre qui fusionneront pour former IBM. Pour une histoire de la discipline, lire l'article de David Donoho, *50 Years of Data Science* (2017).

1.1.2 Définition

> La science des données unifie la statistique, l'analyse de données, l'informatique et leurs méthodes associées pour **comprendre et analyser des phénomènes réels à partir de données**.

Elle se situe à l'intersection de trois domaines :

- l'**informatique** : techniques de calcul, programmation, stockage ;
- les **mathématiques et la statistique** : modèles, inférence, incertitude ;
- l'**expertise du domaine** : connaissance du contexte de la question.

Un · e *data scientist* écrit du code, l'associe à des connaissances statistiques pour extraire de l'information des données, puis **communique** ses résultats à des publics variés afin d'éclairer une décision.

Deux exemples.

- *Santé* : un hôpital veut prédire quels patients risquent d'être réadmis après leur sortie. Le modèle transmet cette information aux médecins, qui décident de la sortie.
- *Marketing* : un opérateur de téléphonie veut repérer les abonnés qui risquent de résilier (*churn*). Le modèle produit une liste de clients à risque ; l'équipe de fidélisation décide à qui proposer une offre, et laquelle.

Dans les deux cas, le but final n'est pas « d'avoir un modèle », mais d'**aider une décision réelle**, prise par des personnes.

1.1.3 Quatre grands types d'analyse

Type	Question	Techniques	Exemple marketing
Descriptive	Que s'est-il passé ?	tableaux, statistiques, graphiques	tableau de bord des ventes par canal
Diagnostique	Pourquoi est-ce arrivé ?	exploration, corrélations, fouille de données	pourquoi les ventes ont-elles baissé en mars ?
Prédictive	Que va-t-il se passer ?	régression, arbres, apprentissage automatique	quels clients vont résilier ? quelles ventes à Noël ?
Prescriptive	Que faut-il faire ?	optimisation, simulation, recommandation	quel budget publicitaire par canal ? quel produit recommander ?

Ce module couvre surtout l'analyse descriptive (chapitres 3 et 4), les méthodes exploratoires (ACP et classification, chapitres 5 et 6) et quelques méthodes prédictives (régression, arbres de décision).

1.1.4 La science des données en marketing

Le marketing est l'un des domaines qui utilisent le plus les données :

- **connaissance client** : segmentation, valeur client (*customer lifetime value*), analyse RFM (récence, fréquence, montant) ;
- **acquisition** : ciblage publicitaire, attribution des ventes aux canaux (moteur de recherche, réseaux sociaux, emailing…) ;
- **fidélisation** : prédiction de l'attrition (*churn*), programmes de fidélité ;
- **offre** : recommandation de produits, prix, analyse du panier ;
- **expérimentation** : tests A/B (comparer deux versions d'un email, d'une page web, d'une offre sur des clients tirés au hasard).

Le fil rouge marketing de ces notes est une **boutique en ligne fictive** dont les données (clients, commandes, campagne d'emailing) sont simulées par le script `datasets/generer-boutique.R`. Elles sont décrites en détail au chapitre 3, où elles sont utilisées pour la première fois.

1.1.5 Les projets réels sont exigeants

Un projet réel commence souvent par une **question floue** (« pourquoi nos ventes baissent-elles ? »), à laquelle on doit répondre avec des **données imparfaites** : ambiguës, erronées, et presque jamais collectées pour votre question. Les données d'un site de vente sont par exemple collectées pour facturer, pas pour comprendre les clients. L'analyse suit un chemin sinueux et aboutit parfois à des résultats peu concluants. C'est normal : l'enjeu est de rendre ces difficultés visibles plutôt que de les cacher.

Les projets échouent souvent pour les raisons suivantes :

1. décalage entre la vision métier et la vision technique ;
2. objectifs flous ;
3. données de mauvaise qualité ;
4. traitement des données incorrect ;
5. méthodes inadaptées à la question.

1.2 Science des données véridique

1.2.1 Les trois mondes

Yu et Barter (2024) proposent de distinguer trois « mondes » :

1. **la réalité**, que l'on cherche à comprendre ;
2. **les données**, qui n'en sont qu'une *approximation* (mesures partielles, bruitées, collectées dans un contexte donné) ;
3. **le monde des constructions mentales** : nos hypothèses, nos analyses et nos algorithmes.

Un résultat calculé à partir de données vit dans le troisième monde. Pour qu'il nous apprenne quelque chose sur la réalité, il faut justifier chaque passage d'un monde à l'autre. C'est pourquoi un résultat issu de données est une **preuve** (*evidence*) en faveur d'une conclusion, pas une **démonstration**.

Exemple : la colonne `nb_visites` d'un outil d'audience web ne compte pas des *personnes*, mais des sessions de navigateur. Une même personne sur son téléphone et son ordinateur compte deux fois ; une personne qui refuse les cookies ne compte pas. Les données approximent la réalité, avec des écarts qu'il faut connaître.

> **Science des données véridique** : mener des analyses en assumant les jugements humains qu'elles contiennent et en s'appuyant sur la connaissance du domaine, afin d'extraire et de communiquer des informations **utiles et fiables** pour résoudre un problème réel.

1.2.2 Pensée critique : les bonnes questions à se poser

Sur le problème

- La question formulée correspond-elle vraiment à ce qui nous intéresse ?
- La question est-elle éthique ?

Sur les données

- D'où viennent-elles ? La source est-elle fiable ?
- Sont-elles pertinentes pour la question et pour les situations où le résultat sera utilisé ?
- À quoi correspond, dans le monde réel, chaque valeur du tableau ?

Sur l'analyse et les résultats

- Que signifient les résultats dans la réalité ? Sont-ils plausibles ?
- Quelles hypothèses la méthode fait-elle ? Sont-elles raisonnables ?
- Les résultats répondent-ils à la question posée ?
- La façon de les communiquer est-elle fidèle ?

Quand c'est possible, allez **sur le terrain** (le *shoe leather* de D. Freedman) : parlez aux personnes qui produisent les données (vendeurs, service client), observez le processus de collecte.

1.2.3 Se méfier des biais

Biais cognitifs de l'analyste :

- **biais de confirmation** : on vérifie moins un résultat qui correspond à nos attentes ;
- **biais de désirabilité** : on cherche le résultat que l'on pense attendu par les autres (client, responsable, enseignant…).

On ne peut pas éliminer ces biais, même avec de l'entraînement. On peut en revanche cultiver un **scepticisme sain** envers *tous* les résultats, qu'ils confirment ou non nos attentes.

Biais dans les données, très fréquents en marketing :

- **biais de survie** : une enquête de satisfaction envoyée aux clients *actuels* ignore ceux qui sont partis, justement parce qu'ils étaient insatisfaits ;
- **biais de sélection** : les avis en ligne sont surtout laissés par des clients très satisfaits ou très mécontents ; leur moyenne ne représente pas l'ensemble des clients ;
- **biais de mesure** : un changement de l'outil de suivi du site peut créer une « hausse » des visites qui n'existe pas.

1.2.4 Étude de cas : les feux de brousse australiens (2019–2020)

Pendant la saison 2019–2020, des incendies ont ravagé plus de 42 millions d'acres (environ 17 millions d'hectares) en Australie. Le professeur Chris Dickman (Université de Sydney) a estimé que « plus d'un milliard d'animaux ont péri ». D'où vient ce chiffre ?

- **Les données** : il provient d'un rapport de 2007 pour le WWF sur l'impact du défrichement en Nouvelle-Galles du Sud. Le chiffre inclut mammifères (hors chauves-souris), oiseaux et reptiles, mais ni les grenouilles, ni les insectes, ni les autres invertébrés.
- **L'analyse** : on a estimé des densités d'animaux par hectare dans une zone limitée, puis multiplié par la surface brûlée. Cette extrapolation ignore les différences de densité entre régions et leur évolution dans le temps.

Le chiffre n'est pas « faux » : c'était la meilleure estimation possible avec les données disponibles, produite par des personnes de bonne foi. Mais il est **très incertain**, et cette incertitude doit être communiquée.

La même démarche s'applique à un chiffre marketing comme « notre campagne a généré 2 millions d'euros de ventes » : quelles ventes sont comptées ? Celles qui auraient eu lieu sans la campagne sont-elles exclues ? Comment a-t-on extrapolé ?

Cette étude de cas est approfondie dans l'exercice 1.3 en fin de chapitre.

1.3 Le cadre PCS : prédictibilité, calculabilité, stabilité

Le cadre PCS donne des lignes directrices pour **évaluer empiriquement la fiabilité** des résultats à chaque étape d'un projet. Prédictibilité et stabilité fournissent des *indices* de fiabilité ; elles ne la prouvent pas, car il faudrait pour cela tester tous les scénarios possibles. L'esprit est proche de la **réfutabilité** de Karl Popper : un résultat gagne en crédibilité quand il résiste à des tentatives sérieuses de le mettre en défaut.

1.3.1 Prédictibilité

Un résultat est **prédictible** s'il se retrouve dans de nouveaux contextes pertinents. La meilleure preuve consiste à le vérifier sur des données **futures ou externes**. À défaut, on simule ces données futures en découpant le jeu de données :

- **entraînement** : explorer les données et ajuster les modèles ;
- **validation** : comparer les modèles et choisir les réglages ; elle joue le rôle de « données futures » ;
- **test** : évaluation finale, une seule fois, sur des données jamais vues.

Le découpage doit refléter la relation entre les données actuelles et celles auxquelles le résultat sera appliqué :

Situation	Découpage	Exemple marketing
Observations interchangeables	**aléatoire**	visiteurs d'un site tirés au hasard pour étudier ce qui mène à un achat
Données ordonnées dans le temps	**temporel** : le passé pour entraîner, le plus récent pour valider et tester	prévoir les ventes : entraîner sur 2023–2024, valider sur début 2025, tester sur fin 2025
Groupes naturels, application à un nouveau groupe	**par groupes** : un groupe entier va dans un seul ensemble	prévoir les ventes d'un **nouveau magasin** : chaque magasin est entièrement en entraînement, en validation ou en test

En R, un découpage aléatoire simple (60 % / 20 % / 20 %) s'écrit :

```
set.seed(2026)                  # rend le tirage reproductible
n <- 100                        # nombre d'observations
ensemble <- sample(c("entrainement", "validation", "test"),
                   size = n, replace = TRUE, prob = c(0.6, 0.2, 0.2))
table(ensemble)
```

```
#> ensemble
#> entrainement         test   validation
#>           63           19           18
```

Fuite de données (*data leakage*) : de l'information sur la réponse ou sur les données de test « fuit » dans l'entraînement. Les performances mesurées sont alors trop optimistes, et le modèle déçoit une fois déployé. Exemples :

- prédire la résiliation d'un abonnement avec la variable « nombre d'appels au service résiliation », qui n'est connue… qu'une fois le client parti ;
- normaliser les données avec la moyenne calculée sur **tout** le jeu de données, test compris ;
- explorer le jeu de test avant de choisir le modèle.

Faites le découpage avant toute exploration, et vérifiez que chaque variable explicative est réellement disponible **au moment où la prédiction sera faite**.

Data snooping : tester un grand nombre d'hypothèses ou de modèles sur les mêmes données jusqu'à « trouver » un résultat. Si l'on compare 20 objets d'email sans réelle différence, l'un d'eux paraîtra « significativement » meilleur au seuil de 5 % dans près de deux cas sur trois ($1 - 0{,}95^{20} \approx 0{,}64$), par pur hasard. Pour l'éviter : formuler les questions à l'avance, garder un jeu de test intact, et rapporter tout ce qui a été essayé.

1.3.2 Calculabilité

La **calculabilité** concerne le calcul lui-même : l'analyse doit être réalisable avec les ressources disponibles, **reproductible** (même code et mêmes données donnent le même résultat) et docu-

mentée. En pratique :

- écrire le code dans des scripts ou des notebooks, jamais seulement dans la console ;
- fixer la graine des tirages aléatoires (`set.seed()`) ;
- noter les versions de R et des packages (`sessionInfo()`) ;
- utiliser des chemins relatifs et des projets RStudio (chapitre 2).

1.3.3 Stabilité

Un résultat est **stable** s'il change peu lorsqu'on applique des **perturbations raisonnables** à chaque étape :

- à la collecte (autre échantillon : rééchantillonnage *bootstrap*) ;
- au nettoyage (autre façon de traiter les valeurs manquantes ou aberrantes) ;
- à la modélisation (autre algorithme, autres paramètres).

On distingue l'incertitude **aléatoire** (liée à l'échantillonnage) et l'incertitude **épistémique** (liée à nos choix et à nos modèles).

Exemple : une segmentation de clientèle qui change complètement quand on relance l'algorithme avec une autre graine, ou quand on exclut les 1 % de clients aux plus gros montants, ne peut pas servir de base à une stratégie marketing.

1.4 Le cycle de vie d'un projet de science des données

1.4.1 Le DSLC

Le cycle de vie de la science des données (*data science life cycle*, DSLC) décrit six étapes. Illustrons-les avec la question « pourquoi les ventes de la boutique en ligne baissent-elles ? ».

1. **Formuler** un problème du domaine, poser une question précise et collecter des données. *Quelles ventes (chiffre d'affaires, nombre de commandes) ? Comparées à quelle période ? Données : commandes, clients, campagnes, trafic du site.*
2. **Nettoyer, prétraiter et explorer** les données. *Commandes en double, remboursements, effet de saisonnalité.*
3. *(Optionnel)* **Explorer la structure intrinsèque** des données. *Existe-t-il des segments de clients dont le comportement a changé ?*
4. **Modéliser** : entraîner un algorithme prédictif ou mener une analyse inférentielle. *Modèle des ventes en fonction des prix, de la publicité, de la saison.*
5. **Évaluer** les résultats (cadre PCS). *Le modèle prédit-il bien les mois récents ? Les conclusions tiennent-elles avec un autre traitement des remboursements ?*
6. **Communiquer** les conclusions et mettre à jour les connaissances du domaine. *Présentation à l'équipe marketing, avec limites et recommandations.*

Ce cycle n'est **pas linéaire** : on revient souvent en arrière (une anomalie découverte à l'étape 4 oblige à revoir le nettoyage). Tous les projets ne parcourent pas toutes les étapes. Les jugements faits pendant le nettoyage influencent les résultats ; ils doivent donc être documentés. Les experts du domaine doivent être consultés **tout au long** du projet, pas seulement au début.

Quand un résultat est **mis en production**, il est intégré dans un outil utilisé en continu : système de recommandation, score de risque de résiliation recalculé chaque semaine, tableau de bord. Il doit alors être surveillé : les données de demain peuvent différer de celles d'aujourd'hui, même si elles sont collectées de la même façon. Les confinements de 2020 ont par exemple bouleversé du jour au lendemain les habitudes d'achat, et donc la qualité de nombreux modèles de prévision.

1.4.2 CRISP-DM

Dans l'industrie, la démarche de référence pour la fouille de données (*Knowledge Discovery in Databases*, KDD) est **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*, 1999). Elle comporte six phases : compréhension du métier, compréhension des données, préparation des données, modélisation, évaluation et déploiement. On y retrouve la même logique itérative que dans le DSLC.

1.4.3 Gouvernance des données

La **gouvernance des données** désigne les règles qui protègent les données et les personnes qu'elles décrivent : qui peut accéder à quoi, comment les données sont stockées et pendant combien de temps, sur quelle base légale elles sont traitées (en Europe, le RGPD). En marketing, où l'on traite des données personnelles de clients, ces questions sont centrales ; elles sont reprises au chapitre 6.

1.5 Résumé

- La science des données vise à **aider une décision réelle** ; elle combine informatique, statistique et connaissance du domaine.
- En marketing : segmentation, ciblage, attrition, recommandation, tests A/B.
- Un résultat issu de données est une **preuve**, pas une démonstration : il faut l'évaluer avec le cadre **PCS** (prédictibilité, calculabilité, stabilité).
- Se méfier des biais de l'analyste (confirmation, désirabilité) et des biais des données (survie, sélection, mesure).
- Découper les données (entraînement / validation / test) **avant** toute exploration, selon un découpage adapté (aléatoire, temporel, par groupes) ; éviter la fuite de données et le *data snooping*.
- Le cycle de vie d'un projet est **itératif**.

1.6 Exercices

Exercice 1.1 — Vrai ou faux ? Pour chaque affirmation, indiquez si elle est vraie ou fausse et justifiez brièvement votre réponse.

a. Les données sont toujours une bonne approximation de la réalité.
b. Avec de l'entraînement, il est possible d'éliminer le biais de confirmation.
c. Les résultats calculés à partir d'un jeu de données collecté aujourd'hui peuvent ne pas s'appliquer à des données qui seront collectées à l'avenir, même si les deux jeux de données sont collectés selon le même mécanisme.
d. Dès que votre analyse répond à votre question de domaine, vous avez répondu de manière concluante.
e. Il existe plusieurs façons de démontrer la prédictibilité de vos résultats.
f. Il existe de nombreuses façons de formuler un problème de science des données.
g. Les évaluations de prédictibilité, de calculabilité et de stabilité (PCS) ne sont nécessaires que lorsque vous présentez vos résultats à un public externe.
h. Une fois que vous avez avancé à une nouvelle étape du cycle de vie de la science des données (DSLC), il est acceptable de revenir à des étapes précédentes et de les mettre à jour.
i. Il n'existe qu'une seule bonne façon de mener chaque analyse de données.
j. Chaque projet de science des données doit passer par toutes les étapes du DSLC.
k. Les jugements effectués lors de l'étape de nettoyage des données peuvent influencer

les résultats ultérieurs.

l. La communication avec les experts du domaine n'est importante que pendant la phase de formulation du problème.

Éléments de réponse

a. **Faux.** Les données ne sont qu'une approximation, partielle et bruitée, de la réalité, collectée dans un contexte donné (les « trois mondes »). Leur qualité doit toujours être examinée.

b. **Faux.** On ne peut pas éliminer ce biais ; on peut seulement le limiter en vérifiant **tous** les résultats avec le même scepticisme, qu'ils confirment ou non nos attentes.

c. **Vrai.** Le monde change : comportements, prix, contexte (les confinements de 2020 ont bouleversé les habitudes d'achat). Un résultat mis en production doit être surveillé.

d. **Faux.** Une réponse n'est qu'une **preuve** en faveur d'une conclusion. Il faut encore évaluer sa prédictibilité et sa stabilité, et communiquer son incertitude.

e. **Vrai.** Vérification sur des données futures ou externes, sur un jeu de validation ou de test, avec différents découpages, par réplication de l'étude…

f. **Vrai.** Une question floue (« pourquoi les ventes baissent-elles ? ») peut se traduire en plusieurs questions précises, mesurées de différentes façons (chiffre d'affaires, nombre de commandes, clients actifs…).

g. **Faux.** Le cadre PCS s'applique **à chaque étape** du projet, d'abord pour soi-même : c'est ce qui permet de faire confiance à ses propres résultats.

h. **Vrai.** Le DSLC est **itératif** : une anomalie découverte pendant la modélisation oblige souvent à revoir le nettoyage, voire la question.

i. **Faux.** De nombreux choix raisonnables existent à chaque étape (nettoyage, méthode, paramètres). Explorer ces alternatives, c'est précisément évaluer la **stabilité**.

j. **Faux.** Certaines étapes sont optionnelles (l'exploration de la structure intrinsèque) ; un projet descriptif n'a pas forcément de modèle prédictif.

k. **Vrai.** Le traitement des valeurs manquantes ou aberrantes, par exemple, peut changer les conclusions. Ces jugements doivent être documentés et leur influence testée.

l. **Faux.** Les experts du domaine sont utiles **tout au long** du projet : pour comprendre ce que signifient les données, juger de la plausibilité des résultats et les communiquer.

Exercice 1.2 — Preuve et incertitude.

1. Expliquez pourquoi un résultat dérivé de données doit être considéré comme une **preuve** plutôt qu'une **démonstration** d'un phénomène réel.
2. Décrivez au moins deux sources d'incertitude associées à tout résultat fondé sur les données.
3. Décrivez deux techniques (quantitatives ou qualitatives) qui permettent de renforcer la crédibilité d'un résultat fondé sur les données.

Éléments de réponse

1. Un résultat est calculé dans le « monde des constructions mentales », à partir de données qui n'approximent la réalité que partiellement, et à travers des choix humains (nettoyage, méthode). Il **soutient** une conclusion sans la garantir : une démonstration supposerait d'avoir testé tous les scénarios de données et d'analyse possibles, ce qui est impossible.
2. Par exemple : l'**échantillonnage** (avec un autre échantillon, on aurait obtenu un

autre résultat), la **mesure** (erreurs de saisie, définition des variables), les **choix de nettoyage** (traitement des valeurs manquantes) et les **choix de modélisation** (méthode, paramètres).

3. **Quantitatives** : vérifier la prédictibilité sur un jeu de test ou des données externes ; tester la stabilité en perturbant les données (*bootstrap*) ou les choix d'analyse. **Qualitatives** : confronter le résultat aux experts du domaine, vérifier sa plausibilité, aller observer le terrain.

Exercice 1.3 — Les feux de brousse australiens.

1. Énumérez au moins deux raisons pour lesquelles les calculs du professeur Dickman pourraient ne pas refléter fidèlement le nombre réel d'animaux morts lors des incendies de brousse en Australie.
2. Imaginez que vous disposiez de ressources illimitées. Décrivez les données hypothétiques que vous collecteriez, et la manière dont vous les collecteriez, afin de répondre à la question du nombre d'animaux morts avec la plus grande précision possible. Soyez précis : quelles valeurs mesureriez-vous, et comment les mesureriez-vous physiquement ?

Éléments de réponse

1. Les densités d'animaux proviennent d'une étude de 2007 sur une zone limitée de Nouvelle-Galles du Sud : elles varient d'une région à l'autre et ont pu évoluer depuis. Le calcul suppose que tous les animaux présents sur les surfaces brûlées sont morts, alors que certains ont pu fuir ou survivre ; à l'inverse, des animaux ont pu mourir après les feux (faim, perte d'habitat). Enfin, le chiffre exclut grenouilles, insectes et invertébrés.
2. Par exemple : avant les feux, des inventaires de faune par espèce dans des parcelles tirées au hasard dans chaque type de végétation et chaque région (pièges photographiques, transects, captures-recaptures, relevés acoustiques pour les oiseaux) ; après les feux, les mêmes relevés sur les mêmes parcelles, brûlées ou non, pour estimer la mortalité par comparaison ; cartographie précise des surfaces brûlées par satellite ; suivi dans le temps pour mesurer la mortalité différée.

Exercice 1.4 — Prédictibilité, stabilité et pièges.

1. Quel est le rôle du jeu de données de **validation** dans l'évaluation de la prédictibilité d'un résultat fondé sur les données ?
2. Décrivez une technique permettant d'évaluer la **stabilité** d'un résultat.
3. Décrivez ce qu'est une **fuite de données** (*data leakage*) et comment l'éviter.
4. Décrivez ce qu'est le ***data snooping*** (exploration abusive des données) et comment l'éviter.

Éléments de réponse

1. Il joue le rôle de **données futures** : il n'est pas utilisé pour ajuster les modèles, ce qui permet de mesurer honnêtement leur performance et de choisir entre plusieurs modèles ou réglages. Le jeu de test sert ensuite à une évaluation finale.
2. Par exemple, le **bootstrap** : refaire l'analyse sur de nombreux échantillons tirés avec remise dans les données, et regarder si le résultat varie beaucoup. On peut aussi refaire l'analyse avec d'autres choix de nettoyage, une autre méthode ou une autre graine aléatoire.

3. De l'information sur la réponse ou sur les données de test se retrouve dans l'apprentissage (variable connue seulement après l'événement à prédire, normalisation calculée sur toutes les données…), ce qui rend les performances trop optimistes. On l'évite en découpant les données **avant toute exploration** et en n'utilisant que des variables disponibles au moment de la prédiction.
4. Tester de nombreuses hypothèses sur les mêmes données jusqu'à en trouver une « significative » par hasard. On l'évite en fixant les questions à l'avance, en gardant un jeu de test intact et en rapportant tout ce qui a été essayé.

Exercice 1.5 — Choisir un découpage. Quelle technique de séparation (par groupes, temporelle ou aléatoire) serait la plus appropriée pour créer les ensembles d'entraînement, de validation et de test dans chacun des scénarios suivants ?

a. Utiliser des données météorologiques historiques pour développer un algorithme de prévision du temps.
b. Utiliser des données provenant d'enfants de 20 écoles parisiennes pour évaluer la relation entre la taille des classes et les résultats scolaires dans d'autres écoles de Paris.
c. Utiliser les données d'élections précédentes pour développer un algorithme de prédiction des résultats d'une élection à venir.
d. Utiliser les données d'un sous-ensemble aléatoire des visiteurs d'une boutique en ligne pour identifier les caractéristiques associées à l'achat d'un produit.

Éléments de réponse

a. **Temporelle** : on prévoit le futur à partir du passé ; les années les plus récentes servent à la validation et au test.
b. **Par groupes** (écoles) : le résultat doit s'appliquer à d'autres écoles ; toutes les classes d'une même école vont dans le même ensemble.
c. **Temporelle** : les élections les plus anciennes pour l'entraînement, les plus récentes pour la validation et le test.
d. **Aléatoire** : les visiteurs tirés au hasard sont à peu près interchangeables.

Exercice 1.6 — Cycle de vie.

1. Que signifie le fait qu'un résultat ou une analyse soit « mis en production » ?
2. Décrivez brièvement chacune des étapes du cycle de vie de la science des données (DSLC).

Éléments de réponse

1. Le résultat est intégré dans un outil utilisé en continu, souvent de façon automatique (score de risque recalculé chaque semaine, système de recommandation, tableau de bord). Il doit alors être surveillé, car les données futures peuvent différer de celles qui ont servi à le construire.
2. (1) Formuler la question du domaine et collecter les données ;
   (2) nettoyer, prétraiter et explorer les données ; (3) explorer éventuellement leur structure intrinsèque ; (4) modéliser ou mener une analyse inférentielle ; (5) évaluer les résultats avec le cadre PCS ;
   (3) communiquer les conclusions et mettre à jour les connaissances du domaine. Le cycle est itératif.

Exercice 1.7 — Découpage en marketing. Pour chacun des projets suivants, proposez un découpage entraînement / validation / test et justifiez-le.

1. Prédire le chiffre d'affaires hebdomadaire d'une enseigne pour les trois prochains mois.
2. Prédire le panier moyen des clients d'un magasin qui va ouvrir à Lille, à partir des données de 40 magasins existants.
3. Prédire, parmi les visiteurs d'un site, ceux qui vont acheter, à partir d'un échantillon aléatoire de visites.

Éléments de réponse

1. Découpage **temporel** : on entraîne sur les semaines les plus anciennes et on valide et teste sur les plus récentes. Un découpage aléatoire laisserait le modèle « voir le futur ».
2. Découpage **par groupes** (magasins) : chaque magasin est entièrement dans un seul ensemble, pour mesurer la performance sur des magasins jamais vus.
3. Découpage **aléatoire** : les visites tirées au hasard sont à peu près interchangeables. Attention toutefois : si un même visiteur apparaît plusieurs fois, il vaut mieux découper par visiteur.

Exercice 1.8 — Fuite de données. Une banque veut prédire, au moment de l'ouverture d'un compte, si le client souscrira une assurance dans l'année. Le fichier contient : âge, revenu, canal d'ouverture, montant des primes payées, nombre de contacts avec un conseiller, date de souscription. Quelles variables posent problème ? Pourquoi ?

Éléments de réponse

Le **montant des primes payées** et la **date de souscription** n'existent que si le client a souscrit : ils révèlent la réponse. Le **nombre de contacts avec un conseiller** est ambigu : s'il est compté sur toute l'année, il inclut des contacts postérieurs à l'ouverture, voire liés à la souscription elle-même. Seules les informations disponibles **à l'ouverture du compte** doivent être utilisées.

Pour aller plus loin

- B. Yu et R. Barter, *Veridical Data Science*, chapitres 1 et 2 (vdsbook.com).
- D. Donoho, « 50 Years of Data Science », *Journal of Computational and Graphical Statistics*, 26(4), 2017.
- R. Kohavi, D. Tang et Y. Xu, *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*, Cambridge University Press, 2020.